



CENTRO DE CIENCIAS BÁSICAS

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN
INGENIERÍA EN COMPUTACIÓN INTELIGENTE

**“Máquinas de Soporte Vectorial en la Interpretación de Movimiento
para Videojuegos Utilizando Interfaces Cerebro-Computadora”**

TESINA

PRESENTA:

CARLOS ARMANDO MARTÍNEZ MEDINA

DIRECTORAS:

DRA. AURORA TORRES SOTO

DRA. MARÍA DOLORES TORRES SOTO

ASESORES:

DR. FRANCISCO JAVIER ORNELAS ZAPATA

DR. FRANCISCO JAVIER ÁLVAREZ RODRÍGUEZ

DR. ALEJANDRO PADILLA DÍAZ

AGUASCALIENTES, AGS. JUNIO DE 2016

Aguascalientes, Ags., 30 de Mayo de 2016

A quien corresponda:

Por medio de la presente me permito informar que el alumno **CARLOS ARMANDO MARTÍNEZ MEDINA** de la carrera de Ingeniería en Computación Inteligente con **ID: 106491**, ha terminado satisfactoriamente su tesina titulada **"Máquinas de Soporte Vectorial en la Interpretación de Movimiento para Videojuegos Utilizando Interfaces Cerebro-Computadora"**, correspondiente a la materia de Seminario de Investigación II.

Para los fines legales que al interesado convengan se extiende la presente a los 30 días del mes de mayo de 2016.

ATENTAMENTE



DRA. AURORA TORRES SOTO
DIRECTORA

Aguascalientes, Ags., 30 de Mayo de 2016

A quien corresponda:

Por medio de la presente me permito informar que el alumno **CARLOS ARMANDO MARTÍNEZ MEDINA** de la carrera de Ingeniería en Computación Inteligente con **ID: 106491**, ha terminado satisfactoriamente su tesina titulada **"Máquinas de Soporte Vectorial en la Interpretación de Movimiento para Videojuegos Utilizando Interfaces Cerebro-Computadora"**, correspondiente a la materia de Seminario de Investigación II.

Para los fines legales que al interesado convengan se extiende la presente a los 30 días del mes de mayo de 2016.

ATENTAMENTE



DRA. MARÍA DOLORES TORRES SOTO
DIRECTORA

Aguascalientes, Ags., 1 de Junio de 2016

A quien corresponda:

Por medio de la presente me permito informar que el alumno **CARLOS ARMANDO MARTÍNEZ MEDINA** de la carrera de Ingeniería en Computación Inteligente con ID: **106491**, ha terminado satisfactoriamente su tesina titulada **“Máquinas de Soporte Vectorial en la Interpretación de Movimiento para Videojuegos Utilizando Interfaces Cerebro-Computadora”**, correspondiente a la materia de Seminario de Investigación II.

Para los fines legales que al interesado convengan se extiende la presente a los 30 días del mes de mayo de 2016.

ATENTAMENTE

DR. FRANCISCO JAVIER ORNELAS ZAPATA
ASESOR

Aguascalientes, Ags., 1 de Junio de 2016

A quien corresponda:

Por medio de la presente me permito informar que el alumno **CARLOS ARMANDO MARTÍNEZ MEDINA** de la carrera de Ingeniería en Computación Inteligente con ID: **106491**, ha terminado satisfactoriamente su tesina titulada **“Máquinas de Soporte Vectorial en la Interpretación de Movimiento para Videojuegos Utilizando Interfaces Cerebro-Computadora”**, correspondiente a la materia de Seminario de Investigación II.

Para los fines legales que al interesado convengan se extiende la presente a los 30 días del mes de mayo de 2016.

ATENTAMENTE

DR. FRANCISCO JAVIER ÁLVAREZ RODRÍGUEZ
ASESOR

Aguascalientes, Ags., 1 de Junio de 2016

A quien corresponda:

Por medio de la presente me permito informar que el alumno **CARLOS ARMANDO MARTÍNEZ MEDINA** de la carrera de Ingeniería en Computación Inteligente con ID: **106491**, ha terminado satisfactoriamente su tesina titulada “**Máquinas de Soporte Vectorial en la Interpretación de Movimiento para Videojuegos Utilizando Interfaces Cerebro-Computadora**”, correspondiente a la materia de Seminario de Investigación II.

Para los fines legales que al interesado convengan se extiende la presente a los 30 días del mes de mayo de 2016.

ATENTAMENTE

DR. ALEJANDRO PADILLA DÍAZ
ASESOR

Contenidos

Resumen	1
Introducción	2
Breve introducción	2
Problema a tratar	5
Justificación	5
Estado del arte	8
Descripción del documento	9
Marco teórico	10
La corteza cerebral	10
Electroencefalografía	14
EPOC	15
Inteligencia artificial	15
Aprendizaje máquina	16
Aprendizaje supervisado	16
Máquina de soporte vectorial	17
Selección de características	19
Selección secuencial hacia atrás utilizando dimensión fractal	20
Objetivo general	21
Objetivos específicos	21
Preguntas de investigación	21
Marco de trabajo	22
Marco de Trabajo (SCATTERBRAIN)	22
Toma de muestras EEG	22
Filtrado de señales	23
Selección de características	23
Ajuste de parámetros y entrenamiento de la máquina de soporte vectorial	23
Validación dentro del entorno virtual	24
Resultados y discusiones	25
Toma de muestras EEG	25
Filtrado de señales	27
Selección de características	30
Ajuste de parámetros y entrenamiento de la máquina de soporte vectorial	31
Validación dentro del entorno virtual	33
Conclusiones	34
Bibliografía	37

Resumen

Las interfaces cerebro-computadora han tomado relevancia en los últimos años debido a que permiten valerse por sí mismas a personas con algún tipo de parálisis; son útiles para estudiar el comportamiento del cerebro cuando se desea realizar una acción, se escucha música, se observan distintas imágenes, etc. Aunado al desarrollo de la tecnología para hacer mediciones cada vez más precisas de la actividad cerebral se está obteniendo un mayor entendimiento de este órgano. Este trabajo busca, utilizando hardware comercial, ver si es posible identificar aquellos canales, según el estándar de posicionamiento internacional, de tal forma que se puedan clasificar correctamente las intenciones de movimiento dentro de un juego haciendo uso de una máquina de soporte vectorial auxiliada con dimensión fractal.

Para esto se realizaron una serie de experimentos, según lo establecido en el marco de trabajo **SCATTERBRAIN**, de toma de muestras encefalográficas así como su filtrado y posterior análisis para discriminar canales, gracias a este procesamiento se obtuvieron cuatro grupos distintos del mismo conjunto de señales con los cuales se entrenó un clasificador para después clasificar en tiempo real las intenciones de movimiento del usuario. La precisión obtenida fue baja, pero se encontró que, aunque los resultados de entrenamiento del clasificador fueron muy buenos con cierta configuración, la aplicación dentro de la validación real no fue tan buena como se hubiera esperado. Otro de los resultados de esta investigación, es el desarrollo del marco de trabajo que servirá de referente a futuros investigadores que incursionen en el campo que nos compete.

Introducción

Breve introducción

Una interfaz cerebro-computadora (BCI) por sus siglas en inglés, es un sistema que mide la actividad del sistema nervioso central y la convierte en una salida artificial que reemplaza, almacena, aumenta, suplementa o mejora la salida natural del sistema nervioso central y de este modo cambia las interacciones actuales entre el sistema nervioso central y su ambiente interno o externo (Wolpaw, J. and Wolpaw, 2012). Las interfaces cerebro-computadora tienen sus orígenes en la década de los veinte cuando el científico alemán Hans Berger grabó las primeras señales eléctricas de actividad cerebral, en esa época aún no se contaba con la tecnología necesaria para medir y procesar las señales eléctricas del cerebro. Este avance, junto al desarrollo de técnicas de aprendizaje de máquina y a la invención de dispositivos portátiles, menos costosos para la toma de lecturas, han permitido que un mayor número de personas tengan acceso a la tecnología y por ende haya una mayor producción de contenido referente al tema.

En 1964 se creó la primera interfaz cerebro-computadora cuando el Dr. Grey Walter conectó electrodos directamente a las áreas motoras del cerebro de un paciente y le pidió que utilizara un botón para avanzar diapositivas; esto le permitió detectar información relevante de la actividad cerebral, después conectó el sistema al proyector de manera que éste avanzara las diapositivas cuando se registraran señales similares en el paciente. Descubrió que necesitaría agregar un pequeño retraso al sistema porque la diapositiva avanzaba antes de que el paciente presionara el botón, lo cual generó la primera interfaz cerebro-computadora. El Dr. Grey no publicó los resultados. Después de esto hubo pocos avances, al final del siglo había poco desarrollo en la materia, pero con el desarrollo de nuevas tecnologías se tuvo mayor avance en el área.

Primero se debe entender cómo se visualiza la actividad cerebral al realizar alguna acción ya que la forma natural de comunicación requiere músculos y caminos nerviosos. Se tienen dos tipos de impulsos:

- los eferentes, cuando se envía una señal del cerebro por medio de los nervios en la periferia a algún efector o músculo y
- los aferentes, cuando se recibe una señal de la periferia hacia el sistema nervioso central.

Las interfaces cerebro-computadora buscan proporcionar una alternativa que apoye los impulsos eferentes ya que lee las señales generadas al intentar hacer algo y las traduce en señales de control que envían información directamente a un sistema sin necesidad de utilizar algún medio de comunicación muscular. Esto implica hacer uso de técnicas de procesamiento de señales y reconocimiento de patrones, (que es el área que le corresponde a al estudio de algunas técnicas de aprendizaje máquina).

Las interfaces cerebro-computadora deben tener cuatro partes:

1. la capacidad de leer las señales directamente del cerebro,

2. proveer de retroalimentación al usuario,
3. que la retroalimentación sea en tiempo real y
4. que el sistema se base en un control a partir de intenciones es decir que el sistema sólo actúe cuando el usuario dese realizar alguna acción. (Graumann, Allison, & Pfurtscheller, 2010)

Existen varias formas de generar neuroimágenes, éstas se refieren a la obtención de información gráfica de la actividad cerebral, generada de manera eléctrica a través de alguna técnica que puede ser invasiva o no invasiva.

La electroencefalografía consiste en posicionar electrodos en el cuero cabelludo del paciente para detectar la actividad cerebral, algunas aplicaciones consisten en diagnosticar enfermedades como Alzheimer, Epilepsia y otras; también permite hacer pruebas sobre la calidad del sueño, el aprendizaje o desórdenes de atención.

La técnica de procesamiento de electroencefalografía cuantitativa utiliza técnicas matemáticas como Fourier o el análisis Wavelet para procesar los registros capturados en los distintos electrodos. Como las lecturas de la electroencefalografía son registradas del cuero cabelludo y las señales desde la corteza pueden no ser suficientes para explorar toda la actividad cerebral (así como sus reacciones), aún existen investigadores que se enfocan en utilizar otras técnicas.

La electrocorticografía registra la actividad directamente de la superficie del cerebro. Comparada con la electroencefalografía, esta técnica ofrece una mayor resolución espacial y menor sensibilidad a ruido. Estas señales se capturan por medio de electrodos posicionados encima del cerebro, por lo que se le considera un método invasivo. Una de sus desventajas más importantes es que no es posible realizar experimentos de manera repetida ya que se requiere una intervención quirúrgica, (que obviamente, implica cierto riesgo). Por otro lado, la cantidad de experimentos posibles es mucho menor, ya que a diferencia de la encefalografía el paciente no puede estar realizando actividades que impliquen un movimiento ya que la naturaleza del procedimiento deja inmovilizado al paciente.

La magneto encefalografía es otra técnica utilizada en las interfaces cerebro-computadora y se utiliza para medir la actividad cerebral por medio de los campos magnéticos generados por iones cargados excitados dentro de las células de las neuronas. El uso de esta tecnología tiene varias ventajas; la magneto encefalografía es una técnica con una resolución temporal alta, esto significa que puede detectar eventos temporales de baja escala, cerca de los milisegundos, por lo tanto, es más confiable y acelera la comunicación en las interfaces cerebro-computadora en comparación con las señales de la electroencefalografía. Además, no requiere de la inyección de isótopos o la exposición a rayos X o campos magnéticos ya que es una técnica no invasiva. Se considera un sistema de diagnóstico amigable con el paciente al ser adecuado para realizar estudios sobre niños. El dispositivo utilizado para esta técnica es el superconductor de interferencia cuántica que debe ser utilizado en un cuarto aislado magnéticamente de manera que se reduzca el ruido del campo magnético de la tierra.

La materia gris es un tipo de tejido neuronal que se encuentra en el cerebro y en la espina dorsal. Se compone principalmente de células del cuerpo junto con sus dendritas, es importante medir la actividad eléctrica dentro de ellas; para eso se utilizan las grabaciones neurocorticales ya que permiten medir ésta actividad. Esta técnica graba las señales de la materia gris por medio de arreglos de micro electrodos implementados dentro de la corteza cerebral. Estos dispositivos varían en forma, tamaño y método de anclaje, utilizan análisis histológico, transcriptómico y electrofisiológico sobre una línea de tiempo aguda, de tres días, y crónica, de doce semanas, aunque la atención se centra en implantar pequeños electrodos y recubrimientos neurointegrativos y antiinflamatorios bioactivos.

El procedimiento de imágenes por resonancia magnética funcional utiliza resonancia magnética para establecer un mapa de activación para indicar la actividad del cerebro, mide el flujo y los cambios de oxígeno en la sangre en respuesta a la actividad neuronal. La idea de este procedimiento es que cuando algunas partes del cerebro se involucran en un proceso mental en particular, éstas consumen más oxígeno, por lo tanto, el flujo de sangre aumenta a estos lugares para cubrir la demanda; por lo tanto, la resonancia magnética funcional depende del grado de oxigenación en una región del cerebro.

La espectroscopia infrarroja cercana se utiliza para penetrar el cráneo en la zona frontal u occipital con el fin de poder evaluar las alteraciones hemodinámicas que acompañan a la actividad cerebral, los niveles de hemoglobina oxigenada y desoxigenada, este método es barato, portátil y tiene una resolución temporal aceptable aunque la limitación clave de este método es su dependencia de la naturaleza de la respuesta hemodinámica, ya que los cambios vasculares ocurren unos segundos después de la actividad neuronal asociada. (Fouad, Amin, El-Bendary, & Hassanien, 2015)

Todos estos métodos se enfocan en hacer lectura de la actividad cerebral pero todas ellas se enfrentan a ciertos problemas como una señal débil o muy tenue, lo que conlleva a utilizar amplificadores de señal que pueden ser de mala calidad y alterar la señal; hasta cierto punto, esto sería perjudicial ya que la información obtenida sería errónea.

Otro reto es el ancho de banda, ya que las aplicaciones necesitan una gran cantidad de datos para poder evaluar la intención del sujeto. Esto perjudica el tiempo de respuesta y el control preciso. Las altas tasas de error se presentan al conjugarse factores como señales débiles y transferencias bajas de información, así como alta variabilidad de las señales del cerebro. Por lo tanto, se tendrá un grado alto de errores. Uno de los problemas que compete al área de la computación es la clasificación imprecisa de señales, el cerebro tiene centros de los cuales se capturan las señales usando electrodos. Clasificar estas señales resulta a veces complicado ya que sufren de interferencia de otras señales, tejidos intermedios y a clasificaciones erróneas. (Ramadan, Refat, Elshahed, & Ali, 2015)

Una de las áreas que provee de técnicas de clasificación para las interfaces cerebro-computadora son las de aprendizaje máquina ya que estas tienen el potencial de adaptarse a tareas específicas, entornos

cambiantes y procesamiento adaptativo de señales. Uno de los retos es tratar con pequeñas muestras de información en un espacio de características de altas dimensiones.

En las interfaces cerebro-computadora es muy común usar un clasificador lineal, un modelo sencillo que puede presentar dificultades cuando las suposiciones no consideran la existencia de valores atípicos o un fuerte ruido pues éstas son situaciones muy comunes en la obtención de información del cerebro. Los clasificadores lineales por lo general son más robustos que sus contrapartes no lineales porque tienen flexibilidad limitada y esto hace que sean menos propensos al sobre entrenamiento.

Existen clasificadores basados en kernel los cuales tienen una interesante y eficiente particularidad en la que un algoritmo lineal es aplicado sobre un espacio de características no lineal utilizando una transformación por parte del kernel (Müller, Krauledat, Dornhege, Curio, & Blankertz, 2007). Las máquinas de soporte vectorial han sido utilizadas en las investigaciones de las interfaces cerebro-computadora ya que son poderosas para el reconocimiento de patrones y en especial para problemas multidimensionales, las señales recibidas son de alta dimensionalidad con una relación baja de señal-ruido. (Selim, Wahed, & Kadah, 2008)

En este trabajo se plantea el utilizar la máquina de soporte vectorial con el kernel de la función de base radial con el objetivo de intentar clasificar señales encefalográficas en base a un marco de trabajo que se expone en las siguientes secciones.

Problema a tratar

El problema que se encontró fue que, aunque existen esfuerzos relacionados con el manejo interfaces cerebro-computadora no se encontró evidencia de la existencia de un marco de trabajo específico para máquina de soporte vectorial auxiliado por dimensión fractal para el dispositivo comercial EPOC, por lo que se estableció uno que da especificaciones para cada uno de los pasos y está orientado a entornos virtuales.

Justificación

Una de las principales áreas de aplicación de las interfaces cerebro-computadora ha sido la médica debido a los pacientes que están parcial o totalmente paralizados, pero otro enfoque interesante de esta tecnología está ligada a los videojuegos y el entretenimiento, ya que al combinarla con realidad virtual se pueden generar espacios de simulación que pueden servir de campo de pruebas para realizar experimentos en los cuales los usuarios se ven forzados a utilizar su cerebro para realizar acciones tales como avanzar, mover objetos, hacer selecciones, etc. Esto abre un mundo de posibilidades pues personas que no sufren de alguna parálisis pueden entrar a un mundo virtual donde solo se pueden valer por las interfaces cerebro-computadora y con esto analizar la actividad cerebral ante tales situaciones.

Varias universidades han realizado experimentos entorno a la combinación de la realidad virtual y las interfaces cerebro-computadora para investigar cómo se desenvuelven los usuarios en estos entornos, por ejemplo se realizó un experimento donde un paciente tetrapléjico sentado en una silla de ruedas tenía la tarea de interactuar con personajes dentro de un mundo virtual, el paciente imaginaba el movimiento de sus pies con lo que avanzaba dentro de la simulación en la que el objetivo era hablar con todos los personajes, se reportó que el paciente logró interactuar con todos los personajes que se encontraban en esta calle virtual. (Lucy et al., 2008)

Esto nos demuestra que pese a la opinión popular de que los videojuegos no son benéficos en general se pueden utilizar para analizar como los usuarios interactúan con su entorno, para las interfaces cerebro-computadora los juegos representan una oportunidad para explorar la actividad cerebral mientras los jugadores interactúan con su entorno así como analizar esta misma actividad en relación a la intención del jugador, con esto se quiere decir que si dentro del videojuego se quiere caminar, correr, saltar, etc. Se esperaría que se pudiera reconocer un cierto patrón al realizar estas actividades lo cual se podría utilizar para realizar un filtrado de esta información y obtener una categorización útil que refleje estas actividades o generar nuevos algoritmos que permitan agrupar las señales cerebrales relacionadas a una intención lo cual se podría utilizar en otros campos que utilicen estas mismas interfaces.

Una de las desventajas que se tienen hasta hoy es que el hardware requerido para realizar experimentos de esta naturaleza está fuera del alcance de muchos consumidores ya que es equipo de laboratorio, existen muy pocas opciones de grado comercial las cuales permiten realizar ciertas actividades de esta naturaleza, uno de los retos es, utilizando sistemas comerciales, lograr resultados cercanos a los que se obtendrían utilizando un sistema diseñado para investigación lo cual permitiría un desarrollo mucho más rápido de esta tecnología ya que daría acceso a una población mucho mayor. Dentro de este enfoque se tienen juegos diseñados especialmente para interfaces cerebro-computadora en los cuales se hace una comparativa entre sistemas de grado comercial contra los de laboratorio y se notó que se tuvo un buen desempeño de los usuarios con el sistema comercial pero que se tenía el problema de que el juego se diseñó tomaba tiempo en explicar y solo se disponían de unos minutos por usuario para usar el sistema pero llegó a la conclusión de que sistemas comerciales como el EPOC de Emotiv podrían ser utilizados para diseñar controles que funcionen utilizando la actividad cerebral. (Van Vliet et al., 2012)


También se busca analizar el comportamiento en aplicaciones que no están diseñadas para una interfaz cerebro-computadora lo que permitiría dar una nueva opción de control del juego por lo que se ve como controlador de entrada a las interfaces cerebro-computadora para interactuar con los elementos de un juego, una de las propuestas involucra utilizar elementos faciales para transmitir información del estado de ánimo dentro del juego, comandos de movimiento o interacción con personajes, un ejemplo interesante es el realizado por la universidad de Graz (Scherer, Pröll, Allison, & Müller-Putz, 2012) donde se utilizó un controlador aplicado en el juego *World of Warcraft* para manipular acciones de los personajes, para este fin se creó un complemento para la interfaz del videojuego donde se mostraban indicadores de la intención

del usuario para el movimiento, esto servía para dar retroalimentación al usuario de que se estaba realizando la acción deseada, una de las mayores complicaciones es la velocidad de respuesta de una interfaz cerebro-computadora debido a su baja tasa de transferencia de información comparada con la velocidad de acción que requieren los juegos diseñados para ser jugados con mouse y teclado, para esto el equipo de la universidad utilizó otras herramientas de apoyo para reducir esta deficiencia como fue el uso de macros, incluida en el juego, lo cual permitió reducir el número de comandos, aprovechar la detección de expresiones del sistema EPOC para representar el estado de ánimo del jugador en el personaje, acciones dependientes del contexto en los cuales con una misma señal cerebral se controlaban varias acciones según el objetivo en el juego, por ejemplo, si se está cercano a otro personaje se interactúa con él y con esto mismo estando cercano a un enemigo se le ataca, con esto se trata de subsanar la deficiencia de la velocidad de comunicación.

Esto demuestra que también los videojuegos se pueden utilizar para hacer investigación de nuevas interfaces y modos de comunicación, sería interesante probar estas interfaces en algún juego de primera persona ya que sería como si uno fuera el personaje lo cual cambiaría la percepción de cómo se maneja el juego ya que se ve a través de los ojos del personaje algo que contribuiría mucho sería la combinación con la realidad virtual y limitar el control a solo la interfaz cerebro-computadora. Los videojuegos pueden ser campos experimentales de interacción ya que el modo de juego varía y esto crearía la necesidad de adaptar la interpretación de las intenciones del usuario al tipo de videojuego lo cual requeriría en mayor entendimiento de cómo trabaja el cerebro al querer realizar una acción.

Estado del arte

Para la revisión de la literatura se realizó la búsqueda dentro de las publicaciones de Springer, Elsevier, IEEE y ACM, se utilizaron las palabras claves “**EPOC SVM Fractal Dimension**” las cuales representan de los términos más significantes para este trabajo, la búsqueda proporcionó pocos resultados como se muestra a continuación:



Gráfica 1. Comparativa de resultados entre distintas publicaciones para las palabras clave utilizadas.

De los resultados que se pueden considerar los más relevantes en cuanto a las técnicas utilizadas está (Liu, Sourina, & Hafiyandi, 2013) en el que se aplica máquina de soporte vectorial para la generación de publicidad que se adapte a las personas, también se aplica dimensión fractal pero para la extracción de características, tanto en el conjunto de entrenamiento como durante la clasificación en tiempo real. Ésto podría presentar gran similitud excepto en el objetivo principal de la investigación, el kernel de la máquina de soporte vectorial y la utilización de la dimensión fractal. En (Hadjidimitriou & Hadjileontiadis, 2013) se utilizan también la máquina de soporte vectorial con el kernel RBF para la clasificación de la apreciación musical en dónde también se extrajeron características utilizando dimensión fractal. En (Yuvaraj et al., 2014) se utiliza también la máquina de soporte vectorial para clasificación pero enfocado al Parkinson. De los artículos con mayor similitud se encuentra (Liu, Sourina, & Chai, 2014) ya que se utiliza el algoritmo propuesto, con distinto kernel, el dispositivo que se eligió, la dimensión fractal y la realización de tareas mentales el objetivo que tenían en mente era el de investigar la correlación entre las emociones humanas y la dificultad de las tareas cognitivas.

Cabe resaltar que en todos estos resultados no se aplica la técnica de dimensión fractal como en este trabajo y esto es para la selección y no la extracción de características, así también, este trabajo propone

investigar la precisión que se puede alcanzar al utilizar las señales en crudo sólo aplicando un filtrado previo, pero sin desratización utilizando las transformadas de Fourier o wavelet.

El ejemplo directamente relacionado con el entorno virtual elegido es el realizado por la universidad de Graz, Austria, en (Scherer et al., 2012), ellos hacen una propuesta para nuevas modalidades de control para juegos, en lo que se refieren a la aplicación de las interfaces cerebro-computadora, después realizaron una aplicación para el juego *World of warcraft*, como se puede observar en (Graz University of Technology, 2012), pero la diferencia principal con el trabajo aquí presentado, es el tipo de hardware utilizado y que ellos crearon una interfaz dentro del juego que ayuda a canalizar la intención del usuario y esto permite tener una alta precisión, en este trabajo solamente se utilizará la intención del usuario y lo que logre interpretar el clasificador.

Descripción del documento

Las siguientes secciones describen los fundamentos teóricos en los que se basó esta investigación seguido de una explicación de lo que se estableció como el objetivo general del trabajo, así como los objetivos específicos que se buscan lograr; la siguiente sección describe el marco de trabajo en dónde se habla de cada una de las etapas del desarrollo de los mismos para así continuar con la exposición de los resultados obtenidos y lo que se observó durante el desarrollo del experimento. Este trabajo finaliza con la presentación de las conclusiones sobre este trabajo.

Marco teórico

Para el presente trabajo se buscó combinar conocimientos de las áreas de neurociencia e inteligencia artificial. Desde luego, no se busca abarcar todas las subáreas que comprenden estas ciencias, sino que, a partir de algunos campos, se buscó cumplir los objetivos.

Dentro de la neurociencia, los campos de interés son los relacionados con la corteza cerebral, de la inteligencia artificial tenemos la rama de aprendizaje máquina, que aporta herramientas para clasificar y seleccionar características.

La corteza cerebral

La corteza cerebral humana se encuentra en la parte exterior del cerebro, tiene aspecto arrugado y de naturaleza compleja. Esta zona también recibe el nombre de materia gris, este color es debido a que allí se encuentran las neuronas, las cuales tienen una abundante cantidad de interconexiones, lo que da este característico color; también se tiene una región de color blanca que recibe su color de la mielina, (una sustancia dieléctrica, que cubre las fibras que forman los tractos que pasan por el cerebro). Una de las fisuras laterales más característica es la conocida como la fisura Silvana, que va desde la parte superior del cerebro y coincide con la fisura Rolándica; estas fisuras nos permiten mapear aproximadamente los cuatro lóbulos en los que comúnmente se divide la corteza cerebral, el frontal, el parietal, el occipital y el temporal.(Beaumont, 2008)




Figura 1. Vista lateral de los cuatro lóbulos y las dos fisuras principales (Beaumont, 2008)p.37

Lóbulo frontal

Este lóbulo se considera como el centro de las actividades que nos caracterizan como humanos, aunque es difícil definir que funciones pertenecen a que zona, debido a su tamaño, se considera que la mayoría de la actividad intelectual se desarrolla aquí. Sin embargo, se necesita identificar con la mayor claridad posible las funciones asociadas a esta área.(Beaumont, 2008)

En esta zona se pueden definir ciertas áreas a las que se les relaciona con algunas funciones. En el lóbulo frontal se identifica la corteza motora y premotora, la prefrontal, la orbital y el área de Broca (que sólo existe en el lóbulo frontal izquierdo si la persona es diestra).




Figura 2. Las cuatro principales áreas del lóbulo frontal(Beaumont, 2008)p.51

La zona motora está relacionada con el movimiento, la premotora con un segundo nivel de control de movimiento. La prefrontal se asocia más con la planeación y programación del movimiento que con el movimiento en sí. La orbital se relaciona con aspectos de la personalidad y comportamiento social. El área de Broca organiza la salida del lenguaje.(Beaumont, 2008)

Lóbulo Parietal

Este lóbulo se puede separar en dos regiones funcionales, una tiene que ver con las sensaciones y la percepción, la otra concentra integración de la entrada sensorial principalmente con la visión. Sus principales funciones tienen que ver con la atención visual, la percepción del tacto, movimientos voluntarios dirigidos por una meta, manipulación de objetos en el espacio y la integración de diferentes sentidos que nos permiten entender un concepto.(Queensland Health, 2013)




Figura 3. Las zonas anterior y posterior del lóbulo parietal(Beaumont, 2008)p.96

Lóbulo temporal

Las funciones principales asociadas con el lóbulo temporal tienen que ver con el procesamiento de información auditiva, el reconocimiento de objetos y otra asociada con el almacenamiento a largo plazo de información sensorial. El hipocampo trabaja con las funciones de reconocimiento de objetos y memoria, (con lo que puede organizar la memoria de objetos en el espacio). En este lóbulo también añade un tono afectivo a información sensorial y las memorias.(Kolb & Whishaw, 1996)




Figura 4. Lóbulo temporal, la zona de Heschl hace referencia a la corteza auditiva primaria(Beaumont, 2008)p.73

Lóbulo occipital

Esta zona se localiza en la parte posterior del cerebro, directamente arriba del cerebelo. Su característica más importante radica en la corteza visual primaria la cual recibe e interpreta información de la retina de los ojos, esta corteza es contralateral, es decir, la información recibida a través del ojo izquierdo es recibida por la corteza derecha y viceversa. (SparkNotes, 2007)

Se encuentran tres regiones principales caracterizadas por el tipo de células que se encuentran dentro de ellas, éstas son las regiones de Brodman 17, 18 y 19 que se refieren a regiones occipitales. (Beaumont, 2008)




Figura 5. Lóbulo occipital, se encuentran marcadas las zonas 17, 18 y 19 de Brodman distinguibles por el tipo de células que las componen. (Beaumont, 2008)p.119

Electroencefalografía

La electroencefalografía (EEG) es el registro de la actividad eléctrica del cerebro a través del cuero cabelludo. Las ondas registradas reflejan la actividad eléctrica cortical, las señales son de intensidad baja, (normalmente de micro volts).

Las frecuencias de estas señales son:

- Delta, con frecuencias de 3 Hz o menos, tienden a ser las de mayor amplitud, pero las más lentas.
- Theta, con frecuencias de 3.5 a 7.5 Hz, se clasifican como actividad lenta.
- Alpha, con frecuencias de 7.5 a 13 Hz, normalmente se detectan en las regiones posteriores siendo de mayor amplitud en la región dominante, aparecen en estado de relajación o con ojos cerrados, desaparecen en los casos contrarios.
- Beta, con frecuencias de 14 Hz o mayores, se consideran rápidas, son más evidentes en la parte frontal del cerebro, son dominantes en pacientes alertas, ansiosos o con los ojos abiertos.

Algunas variables a considerar para la clasificación de las señales electromagnéticas son la frecuencia, puede tener comportamiento rítmico, de frecuencia similar, arrítmica, sin una frecuencia constante, y disrítmico, detectada normalmente en grupos de pacientes con ciertas características comunes. El voltaje, depende de la técnica utilizada para hacer las lecturas y tiene características como la atenuación, reducción de la amplitud de la actividad EEG que resulta en la reducción de voltaje, hipersincronía, visto como el incremento de voltaje y actividad rítmica o dentro del rango señales alpha, beta o theta, paroxística, actividad que emerge, por ejemplo, de un ritmo cardíaco acelerado, y aumenta el voltaje rápidamente y después baja a los niveles normales de manera abrupta. La morfología se refiere a la forma de la onda la cual puede ser afectada por la frecuencia de las ondas así como el voltaje, los patrones se pueden agrupar en mono mórficas, la forma está dada por la actividad dominante, polimórficas, caracterizadas por estar compuestas por varias ondas y producir una más compleja, sinusoidales, tienden a tener una forma de onda similar al de la función seno, transitorias, pueden ser picos que duren de 20 a 70 milisegundos u ondas afiladas con duración de 70 a 200 milisegundos. La sincronía que se refiere a la aparición de patrones rítmicos o morfológicamente distintos sobre diferentes regiones de la cabeza. La periodicidad se refiere a la distribución de patrones de onda durante un tiempo, es decir, que tan seguido aparece algún patrón de onda. (McGill University, 2005)

Estos son factores importantes a considerar al momento de obtener las señales de la actividad cerebral. Para poder colocar los electrodos es necesario tener alguna referencia común para posicionarlos y con esto poder repetir experimentos independientemente del hardware utilizado para realizar la EEG para este fin se estableció el sistema 10-20 aceptado como un estándar internacional el cual indica cómo colocar los electrodos en proporción a la cabeza del paciente, esto permite colocarlos de manera que se cubran las

misma regiones de los lóbulos en la corteza cerebral, también se utiliza una nomenclatura que hace referencia a los lóbulos.

Se denota con A corresponde al lóbulo de la oreja, C al central, P_g al nasofaríngeo, P al parietal, F al frontal, F_p al frontal polar, O al occipital y Z a la fisura central. El hemisferio en el que se encuentra se denota por una numeración impar, el izquierdo, y par, el derecho. (Malmivuo & Plonsey, 2012)

EPOC

El hardware EPOC de la compañía Emotiv es un dispositivo que trabaja de manera inalámbrica, consiste de 14 electrodos para la recolección de datos más otros 2 de referencia que permiten posicionar el dispositivo, este sistema está acorde al estándar internacional 10-20 por lo que provee de las posiciones AF3, F7, F3, FC5, T7, P7, O1, O2, P8, T8, FC6, F4, F8 y AF4, y una tasa de muestreo de 128 Hz. En la siguiente ilustración se muestra un mapa de las posiciones descritas en el sistema 10-20, los puntos con contorno naranja son los que provee el sistema EPOC. (Emotiv, 2014)




Figura 6. Esquema de distribución del sistema 10-20, los círculos naranjas indican los electrodos que posee el sistema EPOC

Inteligencia artificial

El ser humano ha intentado conocer acerca de la inteligencia, de aquí que busque saber cómo es que pensamos durante miles de años ya que una entidad pequeña, como el hombre, puede actuar en un entorno mucho más grande y complejo que él.

La inteligencia artificial (IA) pretende no sólo entender, sino construir entidades inteligentes. La IA pretende actuar de manera racional, se dice que es así cuando se realiza la tarea de manera correcta dado lo que se conoce, por lo que se pueden tomar diferentes enfoques ya que también se toma en cuenta el factor humano. Por este motivo, los sistemas actuarían pensando o actuando de manera humana o racional; un ejemplo de esto es la prueba de Turing dónde se busca hacer pensar a una persona que se comunica con otro ser humano y no con una máquina.

El pensar de manera humana requiere que podamos determinar cómo es que pensamos, por lo que se requiere entender cómo hace su trabajo el cerebro, el comportamiento humano y temas similares, esto permitiría generar modelos que dado un problema muestren el comportamiento de un humano que intenta resolverlo.

El actuar de manera racional se refiere a los agentes los cuales son entes que actúan y de ellos se espera que lo hagan de manera autónoma, percibiendo el entorno, creando, cambiando y persiguiendo metas. Estos agentes racionales actúan de manera que se obtenga el mejor resultado o en todo caso que se logre lo mejor posible dado su conocimiento.

El pensar racionalmente tiene que ver con crear sistemas inteligentes basados en las leyes del pensamiento, es decir, la lógica. Este enfoque dice que un sistema inteligente puede resolver cualquier problema solucionable si este se puede describir con una notación lógica. Uno de los problemas principales es que no es fácil representar todos los problemas en una notación lógica, otro es que no es lo mismo resolver un problema teóricamente que prácticamente. (Russell & Norvig, 1995)

Aprendizaje máquina

El aprendizaje máquina es una sub rama de la inteligencia artificial, se enfoca en los algoritmos que les permite a las computadoras aprender, esto quiere decir que dado un conjunto de datos un algoritmo puede inferir información acerca de algunas de sus propiedades para poder hacer predicciones sobre datos que aparezcan después. Esto es posible gracias a que los conjuntos de datos no aleatorios tienden a seguir patrones de los cuales se puede crear un modelo que, tomando los aspectos más importantes del conjunto de datos, generalice el comportamiento de los datos. (Segaran, 2007)

Aprendizaje supervisado

El aprendizaje supervisado se basa en aprender el modelo detrás de un conjunto de datos etiquetados, lo que permite hacer predicciones acerca de información desconocida o nueva, se dice que es supervisado ya que las etiquetas se conocen de antemano. (Raschka, 2014)

Durante el entrenamiento y evaluación del modelo que se genera se definen dos subconjuntos de datos dentro del conjunto, uno de entrenamiento y otro de evaluación. Los parámetros del modelo se basan en el conjunto de entrenamiento solamente. Si el conjunto de prueba se genera bajo el mismo proceso que el de entrenamiento un estimado imparcial del rendimiento general del modelo se puede obtener al probarlo sobre el conjunto de prueba. (Barber, 2011)

Máquina de soporte vectorial

La máquina de soporte vectorial es uno de los algoritmos más populares en el aprendizaje, máquina moderna ya que muchas veces proveen un desempeño de clasificación sorprendente en conjuntos de datos razonables, aunque en conjuntos más grandes no trabajan bien ya que el número de cálculos requeridos no escala bien comparado con el número de muestras de entrenamiento y por lo tanto se vuelve computacionalmente costoso. (Marsland, 2015)

Esta idea se ha mejorado significativamente comparada con la idea original de Vapnik, la primera máquina de soporte vectorial era un hiperplano clasificador que separaba los datos de entrenamiento en un espacio n dimensional según un criterio. El uso de diferentes criterios de selección lleva a alguna variación de algoritmos utilizados por la máquina de soporte vectorial. Por ejemplo, si se tiene como criterio el encontrar un hiperplano que separe los grupos perfectamente, se estaría llegando a la implementación tradicional de la máquina de soporte vectorial de márgenes máximos, si por otro lado se tiene la posibilidad de permitir errores, entonces se puede utilizar una máquina de soporte vectorial de márgenes suaves, lo mismo aplica de en lugar de tratar de separar un grupo de datos, se intenta que estén lo más cerca posible de este hiperplano, entonces esto se convierte en máquinas de soporte vectorial aplicadas a la regresión. Diferentes criterios llevan a diferentes implementaciones de esta técnica. El problema de la clasificación consiste en determinar la categoría a la que pertenece una observación en base a un conjunto previo, esto es, el conjunto de entrenamiento el cual es una colección de datos $T = \{(\bar{x}_1, y_1), (\bar{x}_2, y_2), \dots, (\bar{x}_l, y_l)\}$, donde cada \bar{x} es un vector n dimensional con las características numéricas de una observación, y cada y es una etiqueta cuyo valor pertenece a un grupo de categorías, dicha etiqueta representa la categoría a la cual las característica de una observación, donde \bar{x} pertenece. (Zhang & of Waterloo (Canada)., 2007)

Una forma de describir una observación es mediante un vector de atributos, una observación tiene características que hacen de esta observación distinta a las otras siendo estos atributos cuantitativos o no cuantitativos dependiendo de lo que estemos analizando. Este vector es el que se provee como entrada para un clasificador. Es de las formas más conveniente que existen para describir una observación la cual será analizada por un algoritmo, usualmente todos los vectores de atributos del conjunto de observación están en la misma dimensión, dentro de las técnicas que tratan este tipo de problema están las máquinas de soporte vectorial. (Kubat, 2015)

El hiperplano separador difiere en que tan grande es el margen de separación que se tiene entre las clases y las correspondientes consecuencias del error de generalización dicho esto supóngase que tenemos un producto punto en el espacio \mathcal{H} y un conjunto vectores patrón $x_1 \dots x_m \in \mathcal{H}$. Cualquier hiperplano en \mathcal{H} se puede escribir como $\{x \in \mathcal{H} \mid \langle w, x \rangle + b = 0\}$, $w \in \mathcal{H}, b \in \mathbb{R}$. En esta formulación w es un vector ortogonal al hiperplano: si w tiene la unidad como longitud, entonces $\langle w, x \rangle$ es la longitud de x en dirección w . Entonces la forma canónica del hiperplano está dada por el par $(w, b) \in \mathcal{H} \times \mathbb{R}$ con respecto

a $x_1 \dots x_m \in \mathcal{H}$, y es escalado tal que $\min_{i=1, \dots, m} |\langle w, x_i \rangle + b| = 1$ como se muestra en la figura 7. (Scholkopf & Smola, 2002)




Figure 7. Problema de clasificación separable

Sea x^* el punto de cruce perpendicular del punto x_i y el hiperplano, la distancia con respecto a x_i , es :

$$d_i = \|x_i - x^*\|.$$

Sabemos que la dirección de $x_i - x^*$ es perpendicular al hiperplano $w^t x_i + b$, así que es la misma que la dirección de w y podemos asumir que:

$$x_i - x^* = kw$$

Donde k es un escalar real, como el punto x^* está en el hiperplano sabemos que:

$$w^t x^* + b = 0$$

$$w^t (x_i - kw) + b = 0$$

$$w^t x_i + b - kw^t w = 0$$

Por lo que tenemos que

$$k = \frac{w^t x_i + b}{w^t w} = \frac{w^t x_i + b}{\|w\|^2}$$

Como tenemos que $x_i - x^* = kw$, entonces:

$$d_i = \|x_i - x^*\| = \|k\| \cdot \|w\| = \frac{|w^t x_i + b| \|w\|}{\|w\|^2} = \frac{|w^t x_i + b|}{\|w\|}$$

Así es como sacamos la distancia entre el punto x_i y el hiperplano.(Ng, 2013)

Como mencionamos antes, el tipo de problema de clasificación que la máquina de soporte vectorial con márgenes óptimos resuelve, debe de ser linealmente separable, pero para este tipo de problemas existen múltiples soluciones, lo que diferencia a la máquina de soporte vectorial con márgenes óptimos es que este método selecciona la solución con mayor margen entre los dos conjuntos. (Marsland, 2015)

Sin embargo, varios problemas del mundo real tienen múltiples clases por lo que existen varios métodos para lograr este objetivo. Uno de ellos es el método uno contra todos el cual obtiene un clasificador para M clases; es común construir un conjunto de clasificadores binarios f^1, \dots, f^M , cada uno de ellos entrenados para separar una clase de las demás y combinarlos haciendo la clasificación multiclase de acuerdo a la salida máxima antes de aplicar la función sgn definida como:

$$\text{sgn}(x) = \begin{cases} -1 & \text{si } x < 0 \\ 0 & \text{si } x = 0 \\ 1 & \text{si } x > 0 \end{cases}$$

Al tomar:

$$\text{argmax}_{j=1,\dots,M} g^j(x), \text{ donde } g^j(x) = \sum_{i=1}^m y_i \alpha_i^j k(x, x_i) + b^j$$

Nótese que:

$$f^j(x) = \text{sgn}(g^j(x))$$

Los valores de $g^j(x)$ también se pueden utilizar para rechazar decisiones. Para esto consideres la diferencia entre los dos valores más grandes de $g^j(x)$ como una medida de confianza en la clasificación de x . Si la medida cae fuera de un umbral θ , el clasificador rechaza el patrón y no asigna una clase lo cual podría requerir de la asistencia de un experto para realizar la decisión. (Scholkopf & Smola, 2002)

Selección de características

La selección de características tiene tres objetivos, estos son, mejorar el desempeño de predicción de los predictores, entiéndase clasificación, regresión, etc., proveer predictores más rápidos, porque la cantidad de información a procesar se reduce, y efectivos y establecer un mejor entendimiento del proceso por el cual se generó la información (Guyon & Elisseeff, 2003). En las interfaces cerebro-computadora también ayudaría a identificar las regiones del cerebro que producen actividad relevante para alguna acción y esto permitiría, como se menciona, un mejor entendimiento de cómo se comporta el cerebro humano ya que, con un estudio más a fondo, se podrían definir mejor las regiones que interactúan entre sí para lograr un objetivo.

Selección secuencial hacia atrás utilizando dimensión fractal

Un conjunto de datos se encuentra dentro de un espacio R^d , siendo d la dimensión, sin embargo esto no significa que la dimensión intrínseca de ese conjunto de datos sea d , la dimensión intrínseca es el número de variables libres necesarias para representar el conjunto de datos sin pérdida de información. Para calcular la dimensión intrínseca se pueden utilizar métodos fractales, (los cuales buscan la similitud entre los mismos datos), para esto existen dos técnicas populares, la primera es el método del conteo de cajas (Traina Jr., Traina, Wu, & Faloutsos, 2000), que se basa en definir la cantidad de cajas de tamaño r para cubrir un conjunto de datos de dimensión d , después es hacer un conteo de cuantos puntos hay dentro de alguna caja y calcular la dimensión intrínseca de la siguiente manera:

$$D = \frac{\delta \log \sum_i C_{r,i}^2}{\delta \log r}, r \in [r_1, r_2]$$

Otro enfoque (Camastra & Vinciarelli, 2002) es utilizar la dimensión de correlación, dado un conjunto de datos en R^n con cardinalidad N definimos la integral de correlación $C_m(r)$ como:

$$C_m(r) = \lim_{N \rightarrow \infty} \frac{2}{N(N-1)} \sum_{i=1}^N \sum_{j=i+1}^N I(|x_i - x_j| \leq r)$$

Donde I es la función indicadora:

$$I(|x_i - x_j| \leq r) = \begin{cases} 1 & \text{si } |x_i - x_j| \leq r \\ 0 & \text{si } |x_i - x_j| > r \end{cases}$$

Y la dimensión de correlación está dada por:

$$D = \frac{\ln(C_m(r))}{\ln(r)}, r \in [r_1, r_2]$$

Entonces según Grassberger y Procaccia (Grassberger, 2007) se puede aproximar la dimensión de los datos en un rango para r donde $r \in [r_1, r_2]$ graficando $\ln(C_m(r))$ contra $\ln(r)$ para el rango de valores y la dimensión aproximada de los datos corresponde a la pendiente de la recta generada usando una regresión lineal.

En esta técnica se aplica el algoritmo de selección secuencial hacia atrás aplicando dimensión fractal (Traina Jr. et al., 2000) en el cuál dado un conjunto de características X^n se calcula la dimensión fractal aproximada para ese conjunto y luego se va eliminando cada una de las características y recalcula la dimensión fractal aproximada de los conjuntos con X^{n-1} , dado el porcentaje de similitud se elimina la característica con la cual la dimensión fractal aproximada no varió en ese intervalo. Se continúa hasta que no se elimine ninguna de las características lo cual indica que si se remueve alguna de las restantes la dimensión variará en un porcentaje mayor al establecido.

Objetivo general

Creación de un mecanismo para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal.

Objetivos específicos

- Creación de un marco de trabajo para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal.
- Selección de subconjuntos de características para reducir la dimensionalidad del problema.
- Entrenamiento de la máquina de soporte vectorial con el subconjunto seleccionado.
- Validación del clasificador obtenido.

Preguntas de investigación

- Teniendo una interfaz cerebro computadora de grado comercial, como lo es el EPOC, ¿qué tanta precisión se podrá tener al tratar de manipular el movimiento de un personaje dentro de un videojuego?
- ¿Es factible contar con un marco de trabajo para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal?

Marco de trabajo

En esta sección se expone el marco de trabajo propuesto para interfaces cerebro-computadora utilizando máquina de soporte vectorial y selección de características con dimensión fractal.

Para tratar este tipo de problemas se propone el siguiente marco de trabajo denominado **SCATTERBRAIN** (*Support veCtor mAchines wiTh fracTal dimEnsion foR BRAin INterfaces*):

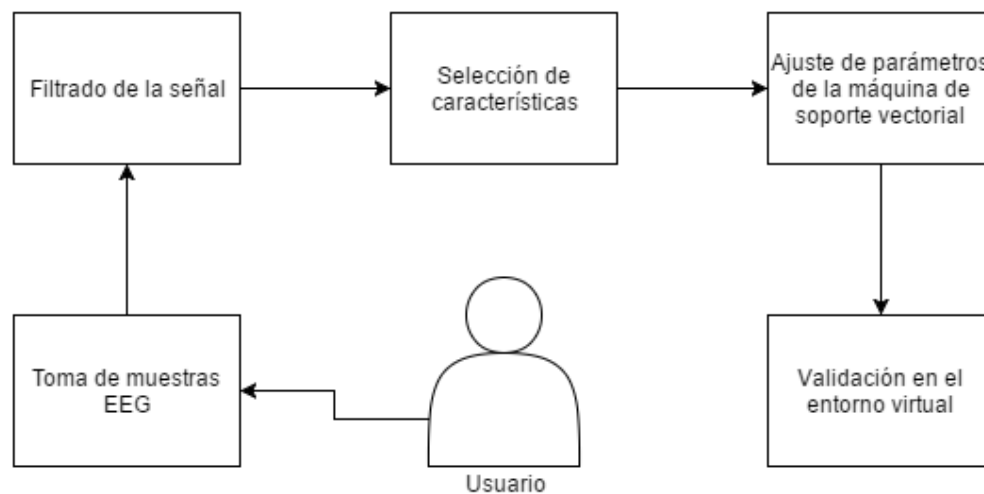


Diagrama 1. Marco de trabajo **SCATTERBRAIN**

Estos pasos representan un marco de trabajo que permitirá obtener resultados similares, aunque esto dependerá mucho de las condiciones en que se tomen las muestras de electroencefalografía, así como las condiciones de la validación dentro del entorno virtual.

Marco de Trabajo (**SCATTERBRAIN**)

En esta sección se describen con mayor detalle los métodos y procedimientos a utilizar en cada una de las etapas del marco de trabajo **SCATTERBRAIN** presentado en la sección anterior.

Toma de muestras EEG

Para realizar la toma de muestras se realizaron dos experimentos ('*EEG_Train_Sorted*' y '*EEG_Test_Sorted*'), en cada uno se realizaron cinco tomas de muestras que después se unieron y ordenaron según su clase y conservando el orden en el que se obtuvieron, cada una consta de lecturas para las cinco clases o intenciones de movimiento, éstas tuvieron una duración aproximada de siete punto ocho segundos, lo que dio como resultado mil muestras de cada clase. Las muestras del primer experimento se utilizaron para entrenar la máquina de soporte vectorial y las segundas para hacer una validación extra y ver cómo se comportó el algoritmo ya entrenado con lecturas que se realizaron en otro momento con circunstancias similares.

Filtrado de señales

Para el filtrado de señales se utilizó un filtro Butterworth de nivel cuatro, esto es debido a que en (Martišius & Damaševičius, 2016) se aplicó uno de ese nivel para filtrado de señales donde se tenían tres intenciones de movimiento, por la similitud del objetivo se optó por utilizar ese nivel y el rango de filtrado fue de entre 0.5Hz y 30Hz según se reporta en (Tschuor, 2002) para una actividad de imaginación del movimiento. En este trabajo se realizó ese filtrado ya que se probó con las señales en crudo y con un filtro sin realizar descomposición de las mismas como se probó, en parte, en (Hammon & De Sa, 2007) lo cual también mostro que la clasificación no fue tan mala. Los datos filtrados guardaron con los nombres 'EEG_Test_Filtered_0.5_30Hz_I4' y 'EEG_Train_Filtered_0.5_30Hz_I4'.

Selección de características

Para realizar la selección de características, se aplicó selección secuencial hacia atrás aplicando dimensión fractal como se menciona en (Traina Jr. et al., 2000), con un error aceptable de 0.015 por ciento; en este trabajo se optó por una disimilitud del 0.005 por ciento.

Lo anterior se debe a que se busca la relación lo más estrecha posible entre variables, se realizó una modificación ya que en el artículo de referencia se menciona el algoritmo de conteo de cajas que fue sustituido por la integral de correlación que también sirve para calcular la dimensión fractal aproximada de un conjunto de datos (Camastra & Vinciarelli, 2002). Esta técnica se aplicó a los conjuntos 'EEG_Train_Filtered_0.5_30Hz_I4' y 'EEG_Train_Sorted'.

Ajuste de parámetros y entrenamiento de la máquina de soporte vectorial

Para calibrar la máquina de soporte vectorial se deben elegir los valores de C y γ , para esto se eligió un rango basado en (Chih-Wei Hsu, Chih-Chung Chang, 2008) en el cual se da como ejemplo un rango de $[2^{-5}, 2^{-3}, \dots, 2^{15}]$ para C y de $[2^{-15}, 2^{-13}, \dots, 2^3]$ para γ , se utilizó la herramienta "GridSearchCV" del "Science Kit Learn" (Pedregosa & Varoquaux, 2011) para hacer un barrido de estos parámetros así como la validación cruzada.

Para los tamaños de las poblaciones de entrenamiento, validación y prueba se utilizó una proporción del 50, 25 y 25 por ciento de los datos, respectivamente, como se menciona en (Marsland, 2015) ya que se considera que se tiene una cantidad abundante de datos.

El kernel utilizado fue la función de base radial, esto es debido a que en estos artículos (Bhuvaneswari & Kumar, 2013; Li, Chen, Yan, Wei, & Wang, 2014) se reporta que es factible aplicar la máquina de soporte vectorial para este tipo de problemas, aunque el enfoque dado en procesamiento de señales es distinto al utilizado en este trabajo como ya se mencionó anteriormente. Se hizo el barrido de parámetros para los

conjuntos 'EEG_Train_Filtered_0.5_30Hz_I4' y 'EEG_Train_Sorted' utilizando el conjunto de características completo y el que dio como resultado para la selección con dimensión fractal, después se hizo una validación extra al clasificar las muestras de 'EEG_Test_Filtered_0.5_30Hz_I4' y 'EEG_Test_Sorted', respectivamente, esto con la finalidad de ver cómo se comportaba el algoritmo con muestras que se obtuvieron en condiciones similares pero en diferentes momentos.

Validación dentro del entorno virtual

Para la validación se hicieron tres pruebas de las intenciones consideradas generando aleatoriamente los grupos, lo anteriormente considerando que se reporta en (Cowan, 2008) que en promedio se pueden recordar una cantidad de cuatro a seis objetos. Así también, se evaluó que tan efectivo es el clasificador para responder a la generación de intenciones para un movimiento errático.

Se generaron cinco secuencias aleatorias (Haahr & Haahr, 2015) de cinco movimientos y estos se probaron con la mejor y peor configuración de la máquina de soporte vectorial.

Para evaluar la intención se tomaron doscientas setenta y ocho muestras, las cuales son un conjunto representativo de la cantidad de lecturas que se tuvieron al realizar los experimentos, este tamaño se considera teniendo un nivel de confianza del 95% con un intervalo de confianza del 5%, esto se aplicó de esta manera como se muestra en (Siuly, Kabir, Wang, & Zhang, 2015), lo que se hizo fue tomar la cantidad señalada de lecturas, filtrarlas, normalizarlas y después obtener el promedio por columna. Esto generó un dato único que fue el considerado por el clasificador.

Se dio un lapso de diez segundos entre cada prueba para que el individuo pudiera recordar la secuencia de movimientos y otro lapso de tres minutos entre cada conjunto de secuencias. Al finalizar se obtuvo el error promedio por configuración de la máquina de soporte vectorial y con esto se obtuvo cuál fue la mejor combinación de selección de características y filtrado aplicado a las señales.

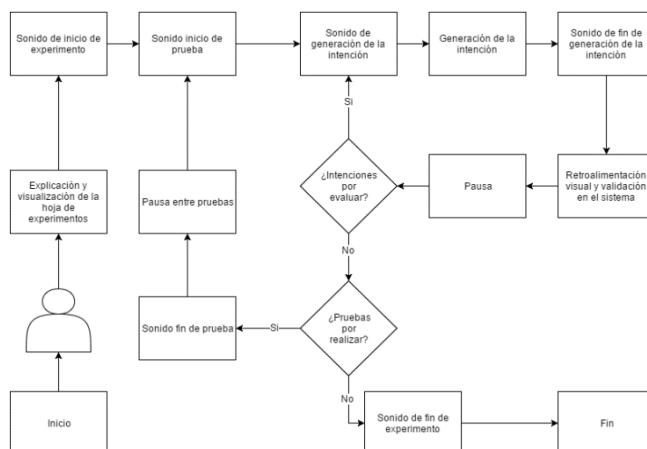


Diagrama 2. Secuencia de validación.

Intenciones de movimiento (Prueba 1)

Intención	Posición fija	Avanzar	Retroceder	Izquierda	Derecha
Figura	●	↑	↓	←	→
1	●	↓	↓	↓	●
2	↑	↓	↓	●	←
3	↓	↓	←	↓	↓
4	●	↑	↓	●	↑
5	↑	←	↓	↓	←

Figura 8. Plantilla de validación

Resultados y discusiones

En este apartado se exponen los resultados obtenidos tras realizar las tareas y procesos señalados en el marco de trabajo **SCATTERBRAIN**. Los experimentos se realizaron sobre un individuo masculino de veinticuatro años de edad; estos mismos se realizaron en la tarde, aproximadamente entre cuatro y seis pasado el meridiano. Se intentó tener un ambiente tranquilo pero que fuese habitual, esto es, que no fuera demasiado forzado ya que en una aplicación real no sería muy conveniente que el usuario requiriera estar en un cuarto aislado, oscuro y libre de ruido.

Toma de muestras EEG

En la figura 9 se observa que hay puntos en los que se corta de repente la señal y después continúa con una frecuencia distinta, esto se puede deber a que en el lapso de toma de lecturas pudo haber alguna distracción o cansancio de mantener la atención durante tanto tiempo. Los picos de actividad indican actividad relevante al observar algo en la pantalla como lo imaginaba el individuo y los canales con más variación en una amplitud baja son F8 y F7:




Figura 9. EEG de intención de no moverse.

En la figura 10 se observa el desfase en la primera y cuarta lecturas, un cambio interesante ocurre en la última lectura en el electrodo FC5 en el cual hay una caída súbita de corriente lo cuál podría indicar una reacción repentina del individuo, se sigue observando una actividad similar en los canales F7 y F8.




Figura 10. EEG de intención de avanzar.

En la figura 11 no se observan cambios bruscos, solo en los electrodos F8 y F7 se puede ver a simple vista un poco mas de actividad durante todos los experimentos para esta clase.




Figura 11. EEG de intención de retroceder.

En la figura 12, al igual que en la 11, la actividad más relevante se registra de igual manera en los electrodos F8 y F7.

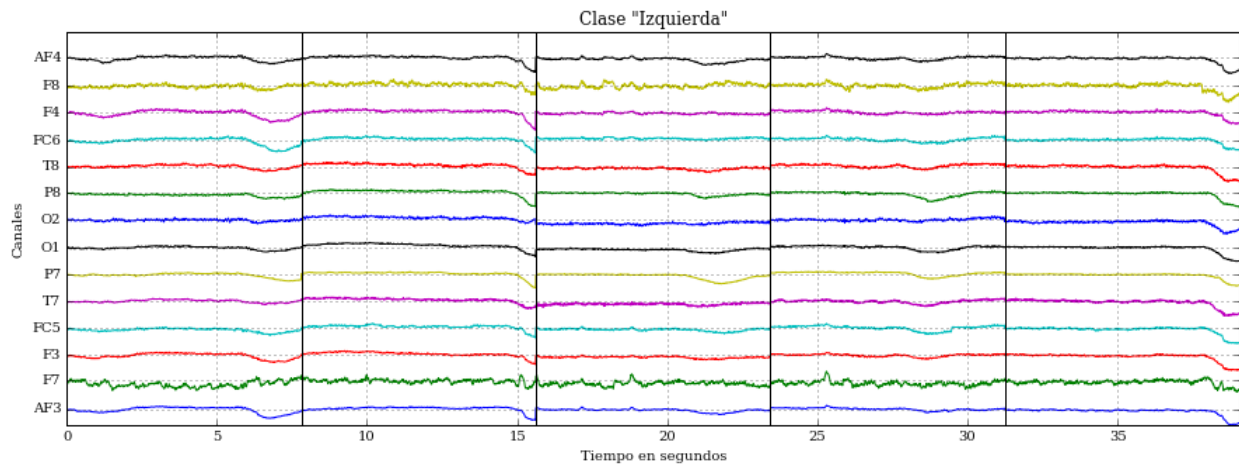


Figura 12. EEG de intención de desplazarse a la izquierda.

En la figura 13 se registró actividad relevante en el segundo experimento y para este caso el electro F8 presenta una actividad más uniforme en comparación a F7 los cuales mostraron actividad relevante en todos los experimentos de todas las clases.




Figura 13. EEG de intención de desplazarse a la derecha.

Las líneas verticales indican la separación entre los experimentos, el desfase entre cada toma de muestras se debe a cambios en la concentración del individuo.

Filtrado de señales

En las siguientes gráficas se muestran las señales filtradas, utilizando un filtro Butterworth de cuarto grado, para cada una de las clases, aunque no se aprecia la reducción en Hertz, debido a la normalización, se puede apreciar el cambio en el comportamiento de las mismas y en general en donde se tiene más variación es al inicio y al final de las señales.




Figura 14. Señal "sin movimiento" filtrada utilizando Butterworth.

En la figura 14 se puede observar la señal asociada a la actividad cerebral de la intención de permanecer fijo en un punto, el filtro Butterworth afectó un poco el comportamiento de la misma, principalmente al inicio.

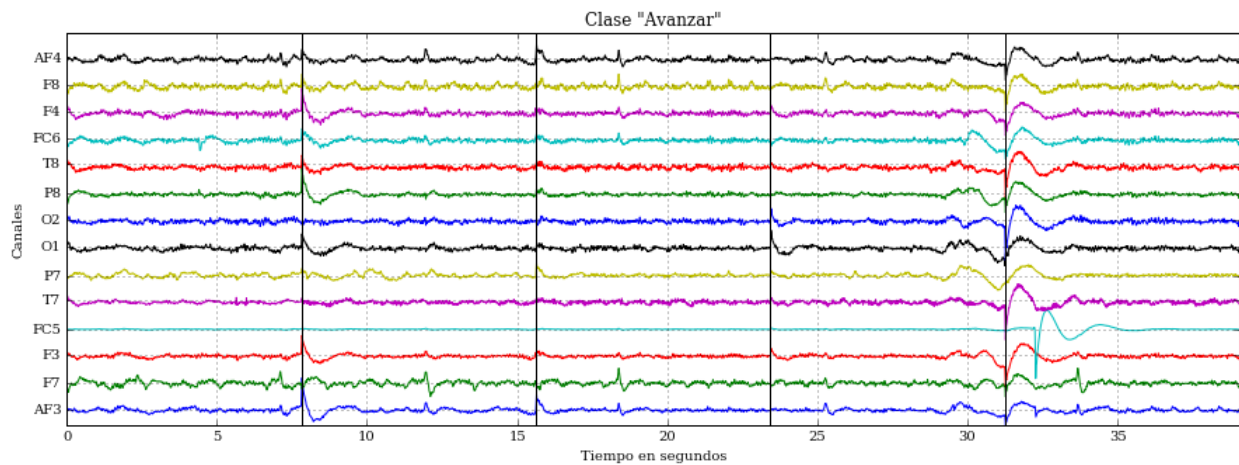


Figura 15. Señal "avanzar" filtrada utilizando Butterworth.

En la figura 15 se observa que el canal que no se afectó tanto, solo en donde se detectó el pico de actividad, fue el FC5, los demás sufrieron la alteración más grande en la señal referente al último experimento de toma de muestras.




Figura 16. Señal "retroceder" filtrada utilizando Butterworth.

En la figura 16 no se observan alteraciones significativas a comparación de la figura 15 por lo que se podría decir que es un poco más similar a la señal filtrada en la figura 14.




Figura 17. Señal "desplazamiento izquierdo" filtrada utilizando Butterworth.

En la figura 17 se observa que el cambio principal ocurre al inicio de la tercera toma de muestras y esto se debe a que en la figura 12, entre el segmento anterior y el tercero se tiene un desfase de la señal lo cual provoca este salto.

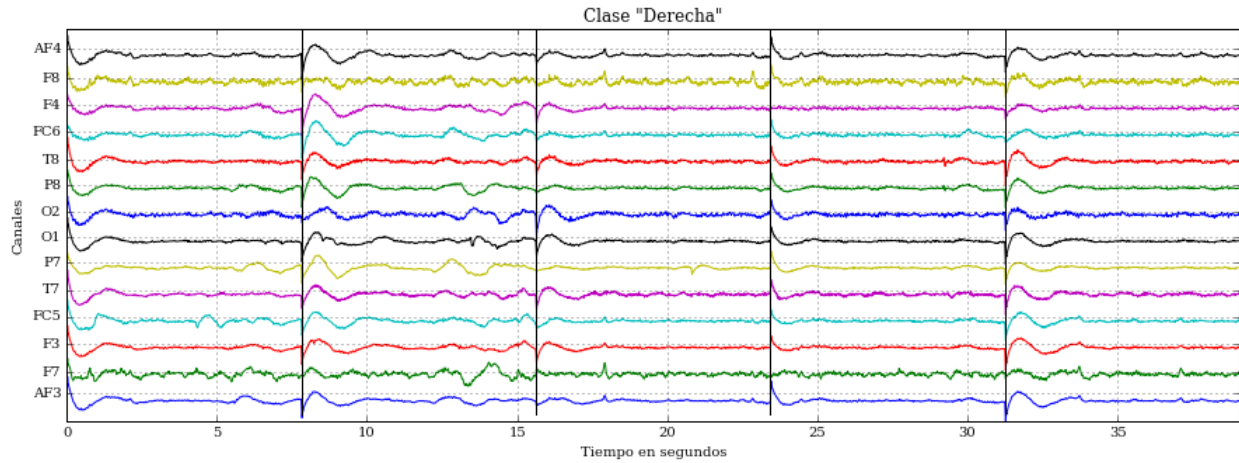


Figura 18. Señal "desplazamiento derecho" filtrada utilizando Butterworth.

En la figura 18, a comparación de las anteriores, no se notan cambios tan drásticos en la señal y aún se conserva la mayor actividad den los canales F8 y F7.

Selección de características

La selección de características se aplicó sobre los datos filtrados y sin filtrar como ya se había mencionado, se muestra la dimensión fractal aproximada del conjunto de datos ya que para lograr esto se requieren $10^{d/2}$ datos (Camastra & Vinciarelli, 2002), donde d es la dimensión dentro de \mathbb{R}^d en la que se puede representar el conjunto, para lograr una aproximación certera lo cual no fue posible de alcanzar en este trabajo; el hecho es que aproximarla no es el fin de la aplicación de la técnica sino lograr encontrar qué variables no hacen que varíe en un 0.005 por cierto el cálculo de la dimensión.

Conservada		Selección de características utilizando dimensión fractal													
Eliminada															
Selección de características	Canales														
	AF3	F7	F3	FC5	T7	P7	O1	O2	P8	T8	FC6	F4	F8	AF4	
Referencia															
EEG_Train_Filtered 0.5_30Hz_I4															
EEG_Train_Sorted															

Tabla 1. Resultados de selección de características para las señales filtradas y no filtradas.

Se observa que de las variables eliminadas existen dos en común mientras que la tercera cambia para ambas muestras por lo que se intuye que las que son comunes para las señales filtradas y sin filtrar son las que en general son irrelevantes para el conjunto de datos aun aplicando alguna transformación, la restante es específica para el conjunto de datos con alguna clase de procesamiento por lo que es probable que pudiese aparecer otra si es que se aplicara una técnica distinta de procesamiento de señales. También

cabe señalar que los electrodos que presentaron mayor actividad para todos los experimentos y clases no fueron eliminados lo cual le da cierta validez al algoritmo utilizado.

Ajuste de parámetros y entrenamiento de la máquina de soporte vectorial

El entrenamiento de la máquina de soporte vectorial se realizó con los datos filtrados y sin filtrar, con y sin selección de características. Utilizando los parámetros para C de $[2^{-5}, 2^{-3}, \dots, 2^{15}]$ y para γ de $[2^{-15}, 2^{-13}, \dots, 2^3]$ se obtuvieron los siguientes resultados:




Figura 19. Resultados de no filtrar la señal y no hacer selección de características.




Figura 20. Resultados de no filtrar la señal y hacer selección de características.

En las figuras 19 y 20 se observa una clasificación casi perfecta lo que podría dar indicios de un sobreajuste de los parámetros hacia el conjunto de entrenamiento, esto se podrá corroborar durante la validación adicional.

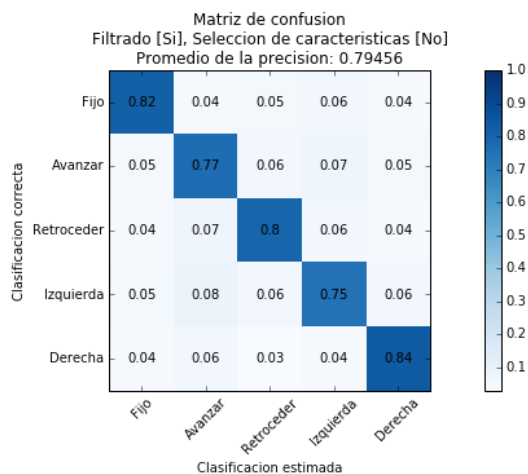


Figura 21. Resultados de filtrar la señal y no hacer selección de características.

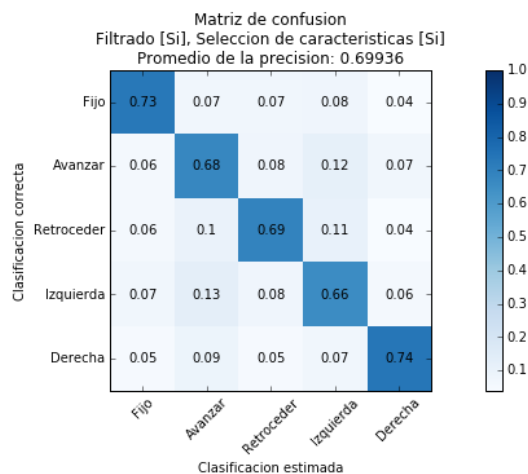


Figura 22. Resultados de filtrar la señal y hacer selección de características.

La figura 21 presenta mayor precisión de clasificación que el mostrado en la 22 pero ambas son peores que las configuraciones para el clasificador mostrados en las figuras 19 y 20.

En general se observa que las clases tienen tendencia a ser afectadas por la clase inmediatas siguientes, esto se piensa que se puede deber a la similitud de los movimiento ya que el desplazamiento es sobre el mismo eje, las intenciones que mejor se clasificaron fueron la de avanzar y permanecer en la misma posición para los cuatro conjuntos de datos, a continuación se muestran las puntuaciones obtenidas por el clasificador así como la puntuación para la clasificación del segundo conjunto de datos con el cual se trata de simular lo que se estará generando en tiempo real con condiciones similares. Nótese que la precisión varía un poco entre el presentado en la matriz de confusión y el reportado en las tablas 2 y 3 ya que en la matriz es el promedio de clasificados correctamente y en las tablas es la precisión obtenida con validación cruzada.

Entrenamiento	Sin selección de características	Con selección de características
Datos de prueba filtrados	0.79456	0.69936
Datos de prueba no filtrados	0.99232	0.97568

Tabla 2. Resultados de entrenamiento de la máquina de soporte vectorial.

Validación	Sin selección de características	Con selección de características
Datos de prueba filtrados	0.1822	0.18032
Datos de prueba no filtrados	0.21152	0.19136

Tabla 3. Resultados de validación de la máquina de soporte vectorial.

Como ya se había visto el conjunto de datos sobre el que mejor se entrena el clasificador es en el que se utilizan las señales en crudo y sin hacer selección de características, mientras que el peor es en el que se aplica filtrado y se eliminan algunas de las variables, después de haber probado entrenar el clasificador con esta combinación de preprocesamiento de los datos se ve que en el que no se aplica nada sigue siendo el mejor para clasificar pero en general las puntuaciones son muy bajas ya que el máximo es de 0.2 lo cual da un indicio de los resultados que tendrá la validación.

Validación dentro del entorno virtual

Para la validación se eligieron la mejor y peor configuración del clasificador. Los grupos de movimientos se consideran difíciles ya que no siguen un patrón esperado de alguien que está en movimiento y quiere llegar a algún punto, más bien representan un movimiento errático lo cual puede dificultar aún más la generación de la intención, después de realizar las pruebas se obtuvieron los siguientes resultados:




Figura 23. Resultados de validación no filtrando la señal y sin aplicar selección de características.




Figura 24. Resultados de validación filtrando la señal y aplicando selección de características.

Los resultados muestran que aunque todo indicaba que el clasificador entrenado utilizando todas las características y sin realizar pre procesamiento de los datos sería el mejor se encontró que no fue así ya que, aunque, la precisión del clasificador fue baja la configuración de hacer selección de características y filtrar fue un 153% mejor, esto es que clasificó un 0.106666 mejor los datos, lo cual tiene cierto sentido ya que en tiempo real hay muchos elementos que se perciben de manera inconsciente y el objetivo del filtrado es eliminar todos esos elementos que se cree que no son relevantes, también se observa que cada configuración tiene fuerte tendencia hacia cierto movimiento, por ejemplo en la configuración sin filtro ni selección se



Figura 25. Escena dentro del juego, entorno virtual, durante la validación.

remarca fuertemente que cuándo la intención era retroceder, se desplazaba a la derecha, observando esta tendencia es lógico que se obtuviera una cantidad de aciertos para esta intención lo cual ocurre, solo que no es tan alta como la intención de retroceder debido a la cantidad de movimientos de este tipo que se esperaban. En cuanto a la configuración de filtrado con selección se observa que se tiene tendencia a avanzar y en dónde se cometieron más errores fue cuando se esperaba que el personaje se quedara fijo en una posición, pero avanzaba, en la figura 23 se observa que cuando la intención fue retroceder se tuvo que un 83% se avanzó y en la figura 24 las tendencias mayores se encontraron en avanzar y mantener la posición en este caso solo una de ellas fue un éxito (avanzar) y el otro un fracaso (mantener la posición). Las puntuaciones obtenidas para la configuración sin pre procesamiento y con pre procesamiento fueron de 0.2 y 0.3066666 respectivamente.

Conclusiones

El objetivo principal de este trabajo fue la ***“creación de un mecanismo para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal”*** lo cual se logró al proponer el marco de trabajo **SCATTERBRAIN** ya que considera los elementos de este objetivo además de contemplar un preprocesamiento de la señal que sirvió para mejorar los resultados durante la validación en el entorno virtual, figura 25, si se compara con los obtenidos al utilizar los datos sin un filtrado de la señal lo cual sirvió de referencia pero lo principal es que el mecanismo contempla desde la toma de muestras, especificación para hacer lecturas en intervalos similares, hasta la validación dentro del juego.

Por otro lado, se cumplió también el objetivo que busca la ***“creación de un marco de trabajo (SCATTERBRAIN) para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal”*** ya que en el marco de trabajo propuesto, se establecen los pasos generales a seguir; el diseño del filtro Butterworth para la señal, la similitud mínima aceptable para aplicar la selección fractal, los rangos de valores para los parámetros de la máquina de soporte vectorial y la rutina de validación dentro del entorno virtual lo cual representa el mecanismo completo para realizar la tarea de toma de muestras.

Para el objetivo que busca la ***“selección de subconjuntos de características para reducir la dimensionalidad del problema”*** se implementó el algoritmo de selección secuencial hacia atrás utilizando dimensión fractal, lo interesante de esta técnica es que no requiere conocer las etiquetas para cada uno de los datos sino que hace un análisis de los datos que consiste en contar que tantos puntos son cercanos a otro y utilizar la suma para calcular la dimensión intrínseca de los datos, esto nos ayuda a discriminar características dado otro enfoque ya que si se tiene un espacio de n características y se aplica

esta técnica es probable que este se pueda representar en un espacio de $n-m$, con $m < n$, lo cual es benéfico para el clasificador.

Con respecto de nuestro objetivo: ***“entrenamiento de la máquina de soporte vectorial con el subconjunto seleccionado”*** se obtuvieron resultados interesantes ya que se esperaba que con la selección de características se tendrían mejores resultados en el entrenamiento y validación, lo cual no fue así y esto es posiblemente causado porque el clasificador que utilizó todas las características se sobre ajustó a las datos y esto podría ser un indicador de sobre entrenamiento aunque cabe señalar que también en la validación obtuvo buenos resultados y cuándo se entrenó con el subconjunto seleccionado de características se obtuvo un porcentaje menor de precisión posiblemente causado por la eliminación de información adicional que pudiese ayudar al clasificador a separar las clases pero también al tener menor precisión es posible que el clasificador tenga una mayor probabilidad de asignar correctamente a una clase un valor desconocido al conjunto de entrenamiento.

Los resultados más interesantes se obtuvieron en la ***“validación del clasificador obtenido”*** ya que el cerebro presenta comportamiento caótico (Korn & Faure, 2003) lo cual hace que, aunque se tengan muy buenos resultados durante el entrenamiento de un clasificador este puede ser pésimo para aplicarlo con señales que se esperarían que fuesen de naturaleza similar. Se encontró, sorprendentemente, en las pruebas de validación dentro del entorno virtual que el clasificador con mayor precisión en entrenamiento tuvo un desempeño menor al que, en entrenamiento, fue el peor y esto puede ser porque esta configuración del clasificador, al tener márgenes que aceptan errores, etiqueta mejor las nuevas señales a comparación de la otra configuración que genera un clasificador mucho más rígido si se toma en cuenta que es para un sistema caótico.

Las preguntas de investigación son dos, una está descrita como ***“Teniendo una interfaz cerebro computadora de grado comercial, como lo es el EPOC, ¿qué tanta precisión se podrá tener al tratar de manipular el movimiento de un personaje dentro de un videojuego?”*** a lo cual se puede responder, en base a los resultados, que la precisión de los clasificadores es baja; debido a la naturaleza del problema y principalmente a que las secuencias de movimiento a reproducir se consideran erráticas lo cual aumenta la complejidad de la tarea para el individuo.

La segunda establece que ***“¿Es factible contar con un marco de trabajo para la interpretación de intención de movimiento mediante la interfaz cerebro-computadora de grado comercial EPOC haciendo uso de una máquina de soporte vectorial apoyada con dimensión fractal?”*** a lo que se puede responder que, en efecto, es posible contar con un marco de trabajo que cumpla con lo establecido en la pregunta, lo único que haría falta sería proponer otros métodos de procesamiento de señal y establecer rutinas probables para las secuencias de validación de movimiento.

Cabe remarcar que este tipo de pruebas son difíciles ya que aunque se tenga un sistema de distribución de electrodos nada garantiza que se registre actividad en las mismas zonas para una misma intención en

distintas personas y también las regiones que se han en las que se han designado los lóbulos puede que no estén estrictamente en esa zona sino que al hacer una comparación entre alguna zona dañada del cerebro y la funcionalidad que se pierde es como se ha definido las funciones de las áreas y bajo ese conocimiento se esperaría que se registrara actividad con el dispositivo utilizado lo cual puede no reflejarse de manera tan clara por las limitaciones de este mismo por lo que sería interesante que se pudiera realizar este mismo experimento con un dispositivo de mayor precisión y cobertura de la superficie cerebral lo cual podría permitir un mejor resultado y también el definir mejor las regiones que participan por medio de una discriminación de los electrodos.

Por último, el que la configuración que dio mejores resultados en entrenamiento y validación no fuera la mejor en la segunda validación podría estar relacionado estrechamente con que tanto confiaba el individuo en el resultado que esperaba, esto es, que cuando se inició la validación y el sujeto percibía que el personaje no realizaba el movimiento correcto para una intención puede que la confianza en la técnica se fuera perdiendo y esto provocara más y más errores, esto es una hipótesis que sería interesante probar, que si la confianza que se tiene en el sistema afecta a la capacidad del individuo de hacer que este funciones correctamente.

Bibliografía

- Barber, D. (2011). Bayesian Reasoning and Machine Learning. *Machine Learning*, 646. <http://doi.org/10.1017/CBO9780511804779>
- Beaumont, J. G. (2008). *Introduction to Neuropsychology*. Guilford Press. Retrieved from <https://books.google.com.mx/books?id=WwR3r0OXGXAC>
- Bhuvaneswari, P., & Kumar, J. S. (2013). Article: Support Vector Machine Technique for EEG Signals. *International Journal of Computer Applications*, 63(13), 1–5.
- Camasta, F., & Vinciarelli, A. (2002). Estimating the intrinsic dimension of data with a fractal-based method. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(10), 1404–1407. <http://doi.org/10.1109/TPAMI.2002.1039212>
- Chih-Wei Hsu, Chih-Chung Chang, and C.-J. L. (2008). A Practical Guide to Support Vector Classification. *BJU International*, 101(1), 1396–400. Retrieved from <http://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>
- Cowan, N. (2008). What are the differences between long-term, short-term, and working memory? *Progress in Brain Research*, 169, 323–338. [http://doi.org/10.1016/S0079-6123\(07\)00020-9](http://doi.org/10.1016/S0079-6123(07)00020-9)
- Emotiv. (2014). EPOC Features. Retrieved from <http://emotiv.com/epoc/features.php>
- Fouad, M. M., Amin, K. M., El-Bendary, N., & Hassanien, A. E. (2015). Brain Computer Interface: A Review BT - Brain-Computer Interfaces: Current Trends and Applications. In E. A. Hassanien & T. A. Azar (Eds.) (pp. 3–30). Cham: Springer International Publishing. http://doi.org/10.1007/978-3-319-10978-7_1
- Graimann, B., Allison, B., & Pfurtscheller, G. (2010). Brain-Computer Interfaces - Revolutionizing Human-Computer Interaction. In *Brain-Computer Interfaces* (pp. 1–27). <http://doi.org/10.1007/978-3-642-02091-9>
- Grassberger, P. (2007). Grassberger-Procaccia algorithm. *Scholarpedia*, 2, 3043. Retrieved from http://www.scholarpedia.org/article/Grassberger-Procaccia_algorithm
- Graz University of Technology. (2012). *Graz-BCI Game Controller - World of Warcraft Mindcontrolled*. Austria. Retrieved from <https://bci.tugraz.at/research/videos>
- Guyon, I., & Elisseeff, a. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182.
- Haahr, M., & Haahr, S. (2015). Random.org. Retrieved from <https://www.random.org/>
- Hadjidimitriou, S. K., & Hadjileontiadis, L. J. (2013). EEG-Based classification of music appraisal responses using time-frequency analysis and familiarity ratings. *IEEE Transactions on Affective Computing*, 4(2), 161–172. <http://doi.org/10.1109/T-AFFC.2013.6>
- Hammon, P. S., & De Sa, V. R. (2007). Preprocessing and meta-classification for brain-computer interfaces. *IEEE Transactions on Biomedical Engineering*, 54(3), 518–525. <http://doi.org/10.1109/TBME.2006.888833>

- Kolb, B., & Whishaw, I. Q. (1996). *Fundamentals of Human Neuropsychology*. W.H. Freeman. Retrieved from <https://books.google.co.uk/books?id=jgpFngEACAAJ>
- Korn, H., & Faure, P. (2003). Is there chaos in the brain? II. Experimental evidence and related models. *Comptes Rendus - Biologies*.
- Kubat, M. (2015). *An Introduction to Machine Learning*. Springer International Publishing. Retrieved from <https://books.google.com.mx/books?id=2EAwCgAAQBAJ>
- L??cuyer, A., Lotte, F., Reilly, R. B., Leeb, R., Hirose, M., & Slater, M. (2008). Brain-computer interfaces, virtual reality, and videogames. *Computer*, 41(10), 66–72. <http://doi.org/10.1109/MC.2008.410>
- Li, X., Chen, X., Yan, Y., Wei, W., & Wang, Z. J. (2014). Classification of EEG Signals Using a Multiple Kernel Learning Support Vector Machine. *Sensors (Basel, Switzerland)*, 14(7), 12784–12802. <http://doi.org/10.3390/s140712784>
- Liu, Y., Sourina, O., & Chai, W. H. (2014). EEG-based emotion monitoring in mental task performance. In *IFMBE Proceedings* (Vol. 43, pp. 527–530). http://doi.org/10.1007/978-3-319-02913-9_134
- Liu, Y., Sourina, O., & Hafiyandi, M. R. (2013). EEG-based emotion-adaptive advertising. In *Proceedings - 2013 Humaine Association Conference on Affective Computing and Intelligent Interaction, ACII 2013* (pp. 843–848). <http://doi.org/10.1109/ACII.2013.158>
- Malmivuo, J., & Plonsey, R. (2012). *Bioelectromagnetism: Principles and Applications of Bioelectric and Biomagnetic Fields*. *Bioelectromagnetism: Principles and Applications of Bioelectric and Biomagnetic Fields*. <http://doi.org/10.1093/acprof:oso/9780195058239.001.0001>
- Marsland, S. (2015). *Machine Learning: An Algorithmic Perspective, Second Edition*. CRC Press. Retrieved from https://books.google.com.mx/books?id=y_oYCwAAQBAJ
- Martišius, I., & Damaševičius, R. (2016). A Prototype SSVEP Based Real Time BCI Gaming System. *Computational Intelligence and Neuroscience*, 2016, 3861425. <http://doi.org/10.1155/2016/3861425>
- McGill University. (2005). EEG Introduction. Retrieved November 8, 2015, from http://www.medicine.mcgill.ca/physio/vlab/biomed_signals/EEG_n.htm
- Müller, K.-R., Krauledat, M., Dornhege, G., Curio, G., & Blankertz, B. (2007). Machine Learning and Applications for Brain-Computer Interfacing. *Human Interface and the Management of Information. Methods, Techniques and Tools in Information Design*, 705–714. http://doi.org/10.1007/978-3-540-73345-4_80
- Ng, A. (2013). *Lecture notes: Support Vector Machines*.
- Pedregosa, F., & Varoquaux, G. (2011). Scikit-learn: Machine learning in Python. ... of Machine Learning ..., 12, 2825–2830. Retrieved from <http://dl.acm.org/citation.cfm?id=2078195>
- Queensland Health. (2013). Parietal Lobe. Retrieved November 8, 2015, from <https://www.health.qld.gov.au/abios/asp/bparietal.asp>
- Ramadan, R. A., Refat, S., Elshahed, M. A., & Ali, R. A. (2015). Basics of brain computer interface. *Intelligent Systems Reference Library*, 74, 31–50. http://doi.org/10.1007/978-3-319-10978-7_2

- Raschka, S. (2014). *Python Machine Learning*. Igarss 2014. <http://doi.org/10.1007/s13398-014-0173-7.2>
- Russell, S. J., & Norvig, P. (1995). *Artificial Intelligence: A Modern Approach*. *Neurocomputing* (Vol. 9). [http://doi.org/10.1016/0925-2312\(95\)90020-9](http://doi.org/10.1016/0925-2312(95)90020-9)
- Scherer, R., Pröll, M., Allison, B., & Müller-Putz, G. R. (2012). New input modalities for modern game design and virtual embodiment. In *Proceedings - IEEE Virtual Reality* (pp. 163–164). <http://doi.org/10.1109/VR.2012.6180932>
- Scholkopf, B., & Smola, A. J. (2002). *Learning With Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. *Journal of the American Statistical Association*. <http://doi.org/10.1198/jasa.2003.s269>
- Segaran, T. (2007). *Programming Collective Intelligence: Building Smart Web 2.0 Applications*. Book. <http://doi.org/10.1016/j.jconhyd.2010.08.009>
- Selim, A. E., Wahed, M. A., & Kadah, Y. M. Machine Learning Methodologies in Brain-Computer Interface Systems, 2008 Cairo International Biomedical Engineering Conference 1–5 (2008). <http://doi.org/10.1109/CIBEC.2008.4786106>
- Siuly, S., Kabir, E., Wang, H., & Zhang, Y. (2015). Exploring Sampling in the Detection of Multicategory EEG Signals. *Computational and Mathematical Methods in Medicine*, 2015, 576437. <http://doi.org/10.1155/2015/576437>
- SparkNotes. (2007). Parietal and occipital lobes. Retrieved November 9, 2015, from <http://web.archive.org/web/20071231064003/http://www.sparknotes.com/psychology/neuro/brainanatomy/section5.rhtml>
- Traina Jr., C., Traina, A. J. M., Wu, L., & Faloutsos, C. (2000). Fast feature selection using fractal dimension. In *Brazilian Symposium on Databases (SBBD)* (pp. 158–171). Retrieved from <http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.84.7306&rep=rep1&type=pdf>
- Tschuor, L. (2002). *Computer Game Control through Relaxation-Induced EEG Changes*. Lausanne. Retrieved from http://mmspg.epfl.ch/files/content/sites/mmspl/files/shared/BCI/publications/rapport_lucasttschuor.pdf
- Van Vliet, M., Robben, A., Chumerin, N., Manyakov, N. V., Combaz, A., & Van Hulle, M. M. (2012). Designing a brain-computer interface controlled video-game using consumer grade EEG hardware. In *2012 ISSNIP Biosignals and Biorobotics Conference: Biosignals and Robotics for Better and Safer Living, BRC 2012*. <http://doi.org/10.1109/BRC.2012.6222186>
- Wolpaw, J. and Wolpaw, E. W. (2012). *Brain-Computer Interfaces: Principles and Practice*. Oxford University Press.
- Yuvaraj, R., Murugappan, M., Ibrahim, N. M., Sundaraj, K., Omar, M. I., Mohamad, K., & Palaniappan, R. (2014). Optimal set of EEG features for emotional state classification and trajectory visualization in Parkinson's disease. *International Journal of Psychophysiology*, 94(3), 482–495. <http://doi.org/10.1016/j.ijpsycho.2014.07.014>
- Zhang, Z., & of Waterloo (Canada), U. (2007). *Customizing Kernels in Support Vector Machines*. University of Waterloo (Canada). Retrieved from <https://books.google.com.mx/books?id=Uki3CG9VZ-YC>